The code is built on a jupyter notebook on gcp. It it about the file modification. And it solves the problem of memory out when reading csv file and modifying data frame by reading by lines and split file into chunks

```
import pandas as pd
import gcsfs
import csv
import google.auth
import numpy as np
from datetime import datetime
currentMonth = datetime.now().month
currentYear = datetime.now().year
currentDay = datetime.now().day
#import boto3
#import dask.dataframe as dd
project = google.auth.default()[1]
fs = gcsfs.GCSFileSystem(project=project)
#file contains 10000003 rows,46columns
#load and separate file into 30 chunks
## read file from gcs
file path="gs://bucketpath/filename"
csvfile=fs.open(file path)
lines=list()
with fs.open(file_path, 'r', encoding='latin1') as readFile:
  reader = csv.reader(readFile)
  for row in reader:
     lines.append(row)
nrow = len(lines)
nrow without header=nrow-1
```

```
#for each chunk:
### split content array into 30 chunks
### turn split arrays into dataframe and modify it(use the same name for dataframes to save
memory)
### save dataframe into a csv file
df=pd.DataFrame(lines)
df=df.iloc[:,0]
headers = df.iloc[0]
content = df.values[1:]
# split content array into 30 chunks (0 to 29)
import numpy as np
a=np.array split(content,30)
#put the header into csvfile
header final = [ ['CustomerID',
'FIRSTNAME', 'LASTNAME', 'ADDRESS1', 'TOWN', 'POSTCODE', 'EMAIL1', 'MOBILE1', 'LAN
DLINE1','Client','Prospect','PossesseurVN','PossesseurVO','PossesseurVP','PossesseurVU','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','PossesseurVD','Possess
ssionInf12Mois', 'Possession30a36Mois', 'Possession42a48Mois', 'PossessionInf4ans', 'Possession4
a8ans', 'PossessionSup8ans', 'Proprietaire', 'Locataire', 'PossesseurRenault', 'PossesseurAutreMarque
PSA', 'Possesseur Segment A', 'Possesseur Segment B', 'Possesseur Segment C', 'Possesseur Segment D', 'Possesseur Segment B', 'Possesseur B', 'Possess
PossesseurBerline', 'PossesseurSUV', 'PossesseurSW', 'PossesseurMonospace', 'PossesseurEssence', 'PossesseurEsseurEssence', 'PossesseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseurEsseur
PossesseurDiesel', 'PossesseurElectrique', 'PossesseurHybride', 'PossesseurPremium', 'PossesseurM
ainstream', 'PossesseurEntry', 'PossessionProcheDateAnniv', 'PossesseurContratEntretien']]
df header=pd.DataFrame(header final)
df header
csvnew="/home/jupyter/filename"
df header.to csv(csvnew, sep='|',index = False, header=False)
##file modification for each chunk (30 loops)
def dataframe modification():
         for i in range(30):
                    ## modification of dataframe
                    # turn split arrays into dataframe and modify it (a[0] to a[29])
                    #select first 46 columns (ignore extra columns of error lines)
                    df chunk=(pd.DataFrame(pd.Series(a[i]).str.split('|').tolist())).iloc[:,0:46]
                    # group columns 4,5,6,7 and put the new column to position 4
                    df chunk[df chunk.columns[4]]=df chunk[df chunk.columns[4:8]].apply(lambda x: '
'.join(x.dropna().astype(str)),axis=1)
                    # deletd: column
CIVILITE, ADRESSE LIGNE 2, ADRESSE LIGNE 3, ADRESSE LIGNE 4
```

```
df chunk=df chunk.drop([df chunk.columns[1],df chunk.columns[5],df chunk.columns[6],df
chunk.columns[7]],axis=1)
    # reorder: change the column order according to the header order
    order = [0,3,2,4,9,8,10,12,11,13,14,15,16,17,18,19,20,21,22,23,24,25,26,27,28,29,
30, 31, 32, 33, 34, 35, 36, 37, 38, 39, 40, 41, 42, 43, 44, 45]
    df chunk = df chunk[order]
    #df chunk.head()
    # put the chunk into a csv file
    df chunk.to csv("/home/jupyter/Jin ok.psv", sep='|', mode='a',index = False, header=False)
    CPL(df chunk)
##file modification for each chunk (30 loops)
def dataframe modification():
  for i in range(30):
    ## modification of dataframe
    # turn split arrays into dataframe and modify it (a[0] to a[29])
    #select first 46 columns (ignore extra columns of error lines)
    df chunk=(pd.DataFrame(pd.Series(a[i]).str.split('|').tolist())).iloc[:,0:46]
    # group columns 4,5,6,7 and put the new column to position 4
    df chunk[df chunk.columns[4]]=df chunk[df chunk.columns[4:8]].apply(lambda x: '
'.join(x.dropna().astype(str)),axis=1)
    # deletd: column
CIVILITE, ADRESSE LIGNE 2, ADRESSE LIGNE 3, ADRESSE LIGNE 4
df chunk=df chunk.drop([df chunk.columns[1],df chunk.columns[5],df chunk.columns[6],df
chunk.columns[7]],axis=1)
    # reorder: change the column order according to the header order
    order = [0,3,2,4,9,8,10,12,11,13,14,15,16,17,18,19,20,21,22,23,24,25,26,27,28,29,
30, 31, 32, 33, 34, 35, 36, 37, 38, 39, 40, 41, 42, 43, 44, 45]
    df chunk = df chunk[order]
    #df chunk.head()
    # put the chunk into a csv file
    df chunk.to csv("/home/jupyter/filename", sep='|', mode='a',index = False, header=False)
    CPL(df chunk)
#Execution (modification + CPL)
dataframe modification()
#Final CPL
cplfile csv="/home/jupyter/CPL final %s%s%s.csv" % (currentDay,currentMonth,currentYear)
df cpl=pd.read csv(cplfile csv)
```

```
droplist=[]
for i in range(1,len(df cpl)):
  if i \% 5 == 0:
    droplist.append(i-1)
#print(droplist)
df cpl=df cpl.drop(df cpl.index[droplist])
for col in range (2,8):
  df cpl[df cpl.columns[col]]=pd.to numeric(df cpl[df cpl.columns[col]])
dtype=df cpl.groupby(by=df cpl.columns[0])['dtype'].unique()
cpl No notzero notnull=df cpl.groupby(by=df cpl.columns[0])
['cpl No notzero notnull'].sum()
cpl No notnull=df cpl.groupby(by=df cpl.columns[0])['cpl No notzero notnull'].sum()
cpl percen notnull=cpl No notnull/nrow without header*100.0
cpl percen notzero notnull=cpl No notzero notnull/nrow without header*100
MaxLen=df cpl.groupby(by=df cpl.columns[0])['MaxLen'].max()
MinLen=df cpl.groupby(by=df cpl.columns[0])['MinLen'].min()
df cpl final=pd.DataFrame(dtype)
df cpl final[1]=pd.DataFrame(cpl No notzero notnull)
df cpl final[2]=pd.DataFrame(cpl percen notzero notnull)
df cpl final[3]=pd.DataFrame(cpl No notnull)
df cpl final[4]=pd.DataFrame(cpl percen notnull)
df cpl final[5]=pd.DataFrame(MaxLen)
df cpl final[6]=pd.DataFrame(MinLen)
df cpl final.columns
=['dtype','cpl No notzero notnull','cpl percen notzero notnull','cpl No notnull','cpl percen no
tnull','MaxLen','MinLen']
df cpl final.index=['TOWN','POSTCODE','EMAIL1','MOBILE1']
cplfile final csv="/home/jupyter/CPL final %s%s%s.csv" %
(currentDay,currentMonth,currentYear)
df cpl final.to csv(cplfile final csv,mode='a',index = True, header= True)
###pb0:to a single file(not supported by gcp)-failed
#df final.to csv(csvnew,sep='|',index = False,encoding='latin1',single file = True,header=True)
###pb1: can't process all lines at once, otherwise memoryout error;
###solution1: cut the file into 30 chunks, modify each;
###pb2: can't append dataframe to csv file in gcs (file in gcs is immutable)
```

###solution2: put the file into jupyternotebook first and then upload it in gcs

###pb3: can't install boto3 (send file to aws);

!gsutil cp /home/jupyter/filename gs://bucketpath/

!gsutil cp /home/jupyter/CPL_final_02022020.csv gs://bucketpath/